

Prototipo de Sistema basado en redes neuronales para la clasificación de pacientes con Covid-19 mediante radiografías torácicas.

Neural network based System prototype for the classification of patients with Covid-19 by means of chest radiographs.

Ronald Juárez ^{1*}, Eugenio Pérez ^{1*}, Cristian Pinzón ^{2*}

¹Licenciatura en Ingeniería de Sistemas y Computación, Centro Regional de Veraguas – Universidad Tecnológica de Panamá

²Docente de Pre-Grado, Centro Regional de Veraguas – Universidad Tecnológica de Panamá

Resumen: Actualmente existen más de 7 millones de personas contagiadas con el nuevo coronavirus SARS-CoV-2 de los cuales le ha cobrado la vida de más de 600 mil personas alrededor del mundo, siendo el motivo principal del actual estado de pandemia decretado por la Organización Mundial de la Salud; Panamá no escapa de esta situación y ya se contabilizan más de 60 mil contagios, la expansión rápida de este virus ha provocado el colapso del sistema actual de salud pública causando una grave ineficiencia a la hora de detectar nuevos contagios y de poder clasificarlos de otras enfermedades respiratorias.

El sistema propuesto se basa en un clasificador de imágenes radiográficas del tórax para la diferenciación de pacientes que presenten síntomas respiratorios provocados por el SARS-CoV-2, este proceso será llevado a cabo mediante el entrenamiento de dos arquitecturas de redes neuronales convolucionales basadas en TransferLearning, la entrada de imágenes se hará mediante un script predictor donde el sistema sea capaz de mostrar el resultado de su inferencia. El preprocesamiento de imagen se realizará utilizando la biblioteca de código abierto TensorFlow así como la impresión de gráficas utilizando la librería NumPy y la utilización de la API Keras para la implementación de las arquitecturas todo esto desarrollado dentro del lenguaje Python.

Palabras claves TransferLearning, coronavirus, radiografías, pandemia, redes neuronales.

Abstract: Currently there are more than 7 million people infected with the new SARS-CoV-2 coronavirus, of which the lives of more than 600 thousand people around the world have been claimed, being the main reason for the current state of pandemic decreed by the World Organization. Of the health; Panama does not escape this situation and there are already more than 60 thousand infections, the rapid expansion of this virus has caused the collapse of the current public health system causing serious inefficiency in detecting new infections and being able to classify them from other diseases. respiratory.

The proposed system is based on a thoracic radiography image classifier for the classification of patients who are presenting respiratory symptoms caused by SARS-CoV-2, this process will be carried out by training two convolutional neural network architectures Based on TransferLearning, the image input will be done through a predictive script where the system will be able to show the result of its inference. Image preprocessing will be done using the TensorFlow open source library as well as printing graphics using the NumPy library and the use of the Keras API for the implementation of the architectures, all developed within the Python language.

Keywords: TransferLearning , coronavirus, x-rays, pandemic, neural networks.

* Corresponding author: ronald.juarez@utp.ac.pa, - eugenio.perez@ utp.ac.pa

* Corresponding assessor: cristian.pinzon@utp.ac.pa

1. -Introducción

El 31 de diciembre del año 2019 en la ciudad de Wuhan, provincia de Hubei en China, la Comisión Municipal de Salud advierte sobre una serie de pacientes que padecían cuadros de neumonía. Un mes después la Organización Mundial de la Salud (OMS por sus siglas) declaró el nuevo brote por coronavirus como una “Emergencia de salud pública internacional” [1].

Mas tarde el 11 de febrero del año 2020 se bautiza al nuevo virus con el nombre “Covid-19” [2]. Para el día 13 del mismo mes, el Gobierno Chino anunció oficialmente que 59 901 pacientes habían dado positivos para el nuevo coronavirus matando a 1 368 personas [3].

El 11 de marzo del año 2020 el director general de la OMS dicta una rueda de prensa declarando al COVID-19 una pandemia mundial, haciendo un llamado a detectar, realizar pruebas, tratar, aislar y rastrear los casos para evitar la propagación en los países [4].

En la ciudad de Panamá el día 9 de marzo del 2020 el Ministerio de Salud (MINSa por sus siglas) declara el primer caso de COVID-19 en el territorio nacional siendo esta una mujer panameña que había ingresado al país procedente de España [5].

Actualmente se sigue en estado de pandemia para la República de Panamá, siendo contabilizados 65 256 casos positivos, 39 166 pacientes recuperados y 1 421 muertes, según cifras del MINSa el 01/08/2020 [6].

Este trabajo investigativo se enfoca en la rápida transmisión del virus y la poca velocidad que se tiene para su detección y diferenciación, específicamente para la provincia de Veraguas en el Distrito de Santiago, siendo el Hospital Luis “Chicho” Fábrega quien acoge la mayoría de los casos en la región, empleando radiografías torácicas para detectar pacientes positivos para la enfermedad, por lo tanto con esta herramienta se puede clasificar el Covid-19 de otras enfermedades respiratorias [7].

2. Descripción de la problemática

Los coronavirus (CoV) conforman un extenso grupo de virus pertenecientes a la subfamilia Orthocoronavirinae dentro de la familia Coronaviridae (orden Nidovirales). Estos virus pueden causar infecciones en los seres humanos y en una serie de animales tanto aves como mamíferos [8].

El nuevo coronavirus SARS-CoV-2, causante del COVID-19 pertenece al género de los beta-coronavirus y guarda parentesco filogenético (homología del 79%) y estructural con el virus SARS-CoV [9], este virus puede propagarse rápidamente mediante pequeñas gotas de saliva y superficies que han sido tocadas por infectados. Tiene un periodo de incubación de 5 y 6 días, con un rango de 1 a 14, desarrollándose el 97,5% de los casos sintomáticos en los 5 días tras la exposición [10].

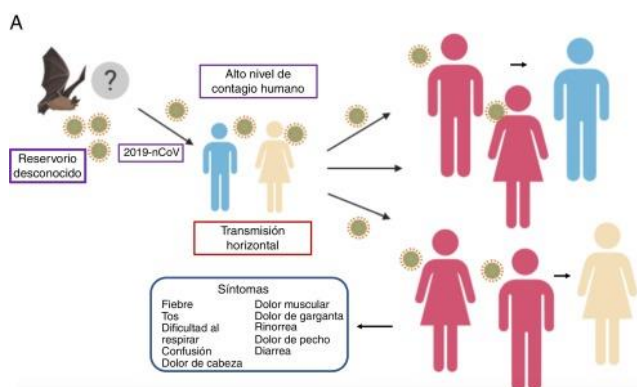


Figura 1. Propagación del COVID-19 en humanos dándose principalmente por vía respiratoria, los síntomas que presenta son parecidos a los de la gripe pudiendo llegar a desarrollar pulmonía grave en pacientes de alto riesgo [11].

Esta enfermedad ha cobrado su tasa de mortalidad debido a que desarrollar bronquitis o neumonía (bien neumonía viral directa o neumonía bacteriana secundaria), hipoxia, síndrome respiratorio agudo severo, fallo o insuficiencia renal [9].




Figura 2. Estado de los pulmones de una paciente de 55 años diagnosticada con Covid-19 sobreviviente a dicha infección, se puede observar una cristalización de sus pulmones mediante pasan los días [7].

Dada esta problemática actual del virus se plantea este proyecto donde se espera aprovechar la capacidad de manifestación del virus en los pulmones para poder ser identificado a tiempo, brindando un margen de reacción suficiente a los médicos en sus tratamientos y diagnósticos.

3. Metodología

Este proyecto se enmarca en la metodología de investigación descriptiva.

3.1. Identificación del problema

Se estableció una problemática dado el estado de pandemia actual, que se pueda resolver dentro del área de medicina interna.

3.2. Revisión bibliográfica

Se realizó una revisión de proyectos similares realizados como referencia para fortalecer la idea del proyecto y comprobar la factibilidad de este.

3.3. Recolección de datos

Los datos recolectados provienen de repositorios y plataformas validados por investigadores internacionales.

3.4. Identificación de tecnologías de software

Mediante la revisión bibliográfica se logró identificar las tecnologías necesarias para el desarrollo del prototipo.

3.5. Diseño del prototipo

Se preparó el conjunto de datos con radiografías torácicas de pacientes positivos por Covid-19 y de otras enfermedades respiratorias.

Se desarrollaron dos modelos de red neuronal utilizando transferencia de conocimiento.

Desarrollo de pruebas para comparar eficacia de ambos modelos.

3.6. Resultados

Los resultados se muestran mediante gráficas y tablas.

3.7. Conclusiones

Se llegan a las conclusiones acerca del proyecto investigativo.




Figura 3. Diagrama de la metodología utilizada para este proyecto.

4. Metodología CommonKADS

TABLA 1. PLANTILLA OM-5 DEL MODELO DE ORGANIZACIÓN PARA LA METODOLOGÍA COMMONKADS REFERENTE AL PROYECTO PLANTEADO.

MODELOS DE LA METODOLOGÍA COMMONKADS	
NIVEL: Contextual	TIPO DE MODELO: Modelo de organización.
FORMULARIO:	OM - 5: <i>Análisis de viabilidad.</i>
APARTADO	ACTIVIDAD
Viabilidad Empresarial	El sistema será capaz de apoyar en el diagnóstico del médico para clasificar si el paciente está sufriendo un cuadro pulmonar producido por el Coronavirus Covid-19, siendo capaz de evaluar que tal afectado están sus pulmones por la enfermedad.
Viabilidad Técnica	Cumpliendo con la fase de prototipo el sistema será rectificado para poder localizar problemas a la hora del aprendizaje. Un riesgo puede ser que el sistema no logre clasificar de manera precisa entre un paciente sano y uno afectado por el Covid-19.
Viabilidad del Proyecto	Ante la espera de una vacuna para mitigar la pandemia, los investigadores del mundo han realizado esfuerzos por crear soluciones tecnológicas basadas en Inteligencia Artificial, que puedan servir de apoyo a los médicos, por ello existe una gran documentación en repositorios Web acerca de proyectos basados en clasificadores neuronales que apoyen en ese sentido.
Acciones Propuestas	Área de Interés: Medicina Interna. Solución Objetivo: Clasificador basado en redes neuronales. Resultados esperados: Se espera tener un software que apoye al médico en su diagnóstico.

Se utilizó la metodología CommonKADS para el análisis y construcción del sistema. En la Figura 1 se muestra la plantilla OM-5 donde se plantea el análisis de viabilidad del proyecto dentro de la organización.

5. Desarrollo

5.1. Machine Learning o Aprendizaje automático

En la actualidad la inteligencia artificial se ha potenciado con el desarrollo del aprendizaje automático, propiciando grandes avances tecnológicos en la gran mayoría de ramas científicas. Podemos definir el Machine Learning como el diseño y estudio de herramientas computacionales que se basan en la experiencia pasada y aprendida, para realizar inferencias o tomar decisiones futuras. Su objetivo fundamental es generalizar, o inducir una regla desconocida a partir de ejemplos donde esa regla es aplicada [12].

Generalmente se clasifica en tres sub-ramas: aprendizaje supervisado, aprendizaje no supervisado y aprendizaje semi-supervisado [13].




Figura 4. Esquema general sobre el Machine Learning.

5.2. Tecnologías utilizadas:

a) Python

Es un lenguaje de programación que fue creado por Guido Van Rossum cerca de los años 90, goza de ciertas características similares al lenguaje Perl denotando una mejor sintaxis que propicia el código limpio y legible. Es un lenguaje interpretado o de script, es decir, utiliza un intérprete para ser ejecutado, esto le brinda la ventaja de ser flexible y portable. Su sintaxis es sencilla guardando semejanza al lenguaje natural por eso se trata de uno de los mejores lenguajes para programar. En resumen se trata de un lenguaje fuertemente tipado, multiplataforma, orientado a objetos y con tipado dinámico [14].

b) TensorFlow

Es una librería de código abierto pensada para un alto rendimiento en computación numérica, aplicada en la construcción y entrenamiento de redes neuronales artificiales. Esta librería está escrita en una combinación de C++ y CUDA (lenguaje de Nvidia para GPU's). Utiliza Eigen (una librería numérica de alto rendimiento para C++ y CUDA) y cuDNN (una librería de Nvidia para redes neuronales profundas) [15].

Su origen se debe a los desarrollos e investigaciones de ingenieros de Google Brains con la organización de inteligencia artificial de Google [16].

Cuenta con una arquitectura flexible pudiendo ejecutarse en multitud de plataformas como GPUs, CPUs, o TPU,s y en ordenadores, servidores o dispositivos móviles, esto aporta un soporte fuerte para Machine Learning y Deep Learning [15].

c) Keras

Keras es una API de Deep Learning o aprendizaje profundo, que se ejecuta en la parte superior de la librería TensorFlow. Fue desarrollado enfocado a permitir la experimentación rápida, propicia una interfaz accesible y productiva para poder dar solución a problemas planteados desde el Machine Learning con el enfoque en Deep Learning brindando a desarrolladores, investigadores e ingenieros aprovechar al máximo la escalabilidad y capacidades multiplataforma de

TensorFlow permitiendo exportar modelos hacia navegadores o dispositivos móviles [17].

d) Numpy

Es una biblioteca para el lenguaje Python que ofrece objetos derivados como matrices enmascaradas, rutinas para realizar operaciones matriciales de ámbito matemático o lógicas, manipulación de formas, clasificación, álgebra lineal, operaciones estadísticas básicas, simulación aleatoria y más. Este paquete demuestra su utilidad para la computación científica gracias a la rapidez de su código vectorizado [18].

e) Anaconda

Es una plataforma Open Source dedicada a la ciencia de los datos (Data Science, Machine Learning, Ciencia, Ingeniería, Big Data, etc). para los lenguajes Python y R incluye más de 100 paquetes populares de Python, R y Scala. Consta de un repositorio en la nube donde se encuentran más de 7 500 paquetes que pueden ser instalados con el administrador de paquetes, dependencias y ambiente, que se incluye en Anaconda [19].

6. Diseño

6.1.1. Selección de la red neuronal

Cuando se trabajan en el análisis y reconocimiento de imágenes se debe utilizar una red neuronal convolucional (CNN por sus siglas en inglés) esta es un tipo de red multicapa compuesta por n capas de convoluciones y de pooling (encargada de submuestreo) y teniendo al final una serie de capas full-connected del tipo perceptrón multicapa, la entrada será una imagen $m \times m \times r$, donde m es tanto la altura como el ancho de la imagen y r es el número de canales de la que se compone la imagen [20]. Este tipo de redes neuronales han tenido un gran auge de desarrollo y aplicación en la última década y todo gracias al rendimiento que denotan sobre otras arquitecturas en el tratado de imágenes [21].

Para la creación del prototipo se empleó una red neuronal convolucional ya que es un tipo de arquitectura especializadas en el estudio de imágenes por medio de vectores.

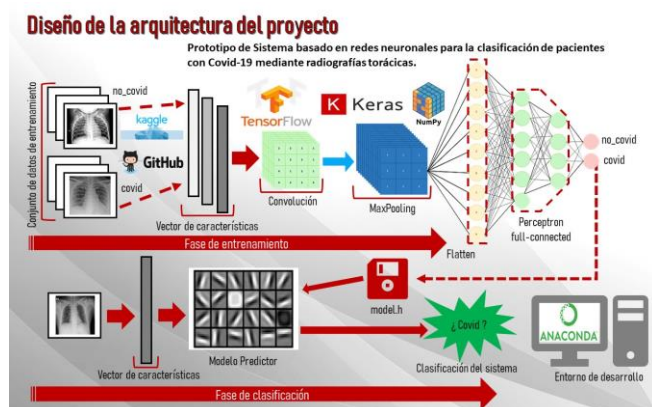


Figura 5. Esquema de la arquitectura del proyecto y tecnologías utilizadas.

6.1.2. Técnica de Transfer Learning

Transferencia de conocimiento por su traducción, se le define como la capacidad que posee un sistema de aprender, reconocer y aplicar conocimientos y habilidades adquiridas de tareas pasadas aplicadas hacia las nuevas que se le presenten [22]. Actualmente existen modelos de redes neuronales convolucionales pre-entrenadas muchas imágenes de todo tipo, estos modelos no requieren iniciar el entrenamiento de los pesos, en lugar de comenzar con valores aleatorios, los pesos vienen ajustados gracias al entrenamiento con otro problema generalmente más grande [23].

En este proyecto se decidió utilizar los modelos MobileNetV2 y VGG16 con el objetivo de medir el rendimiento de ambas arquitecturas para el mismo conjunto de datos.[24][25][26].

TABLA 2. CUADRO COMPARATIVO DE LOS PRINCIPALES MODELOS DE TRANSFERLEARNING DISPONIBLES EN KERAS [27].

Model	Size	Top-1 Accuracy	Top-5 Accuracy	Parameters	Depth
Xception	88 MB	0.790	0.945	22,910,480	126
VGG16	528 MB	0.713	0.901	138,357,544	23
VGG19	549 MB	0.713	0.900	143,667,240	26
ResNet50	98 MB	0.749	0.921	25,636,712	-
ResNet101	171 MB	0.764	0.928	44,707,176	-
ResNet152	232 MB	0.766	0.931	60,419,944	-
ResNet50V2	98 MB	0.760	0.930	25,613,800	-
ResNet101V2	171 MB	0.772	0.938	44,675,560	-
ResNet152V2	232 MB	0.780	0.942	60,380,648	-
InceptionV3	92 MB	0.779	0.937	23,851,784	159
InceptionResNetV2	215 MB	0.803	0.953	55,873,736	572
MobileNet	16 MB	0.704	0.895	4,253,864	88
MobileNetV2	14 MB	0.713	0.901	3,538,984	88

Como se muestra en la Figura VII el modelo VGG16 cuenta con un mayor tamaño debido a la cantidad de parámetros con la que se ha entrenado, en cambio la arquitectura MobileNetV2 es más ligera contando con menos cantidad de parámetros de entrenamiento, esta diferencia brindará la posibilidad de comparar la técnica de TransferLearning aplicada a nuestro proyecto de clasificación.

6.1.3. Conjunto de Datos

Los datos se copilan en gran medida de repositorios y plataformas como lo son GitHub y Kaggle, estos datasets han sido recolectados, probados y utilizados en diferentes artículos científicos brindando cierto grado de confiabilidad, además, la política de confidencialidad de pacientes complica la creación de un dataset propio y validado [7]. Se recopiló el conjunto de datos para este proyecto de las siguientes fuentes [28]–[35]. El conjunto de datos final utilizado se compone de Imágenes radiográficas torácicas de adultos y niños. Este se dividió de la siguiente manera:

- Imágenes de entrenamiento con 77 elementos identificados como Covid-19 y 77 como No Covid.
- Imágenes de validación con 18 elementos identificados como Covid-19 y 65 elementos identificados como No Covid.

- Imágenes de prueba con 80 elementos tanto Covid como No Covid para evaluar el rendimiento del modelo.

En el conjunto de imágenes correspondientes a No Covid se encuentran radiografías de pacientes con pulmones sanos, afectados por enfermedades bacterianas y SARS 1.

6.1.4. Entrenamiento

Para la fase de entrenamiento se utilizó una computadora personal con un procesador Ryzen 3 2200g @3.75 Ghz con 8 GB de RAM, dado que el hardware es una de las limitaciones, los modelos se entrenaron de la siguiente manera:

- 200 épocas para la MobileNetV2
- 40 épocas para la VGG16.

Los pesos iniciales de ambas arquitecturas se congelaron mediante el atributo “trainable = False”, se eliminó la capa de salida y se sustituyó por capas densas correspondientes a las 2 salidas que requeríamos para el sistema. Se emplearon técnicas como el “Dropout” y “EarlyStopping” para prevenir el sobre aprendizaje en ambas redes.



Figura 6. Gráfico Pérdida vs Época para el modelo MobileNetV2 durante la fase de entrenamiento.




Figura 7. Gráfico Pérdida vs Época para el modelo VGG16 durante la fase de entrenamiento.

En el modelo MobileNetV2 se puede observar en la Figura 5 que la pérdida en los datos de validación decreció llegando a estancarse alrededor del valor 0.2 mientras que la pérdida de entrenamiento lograba decrecer un pequeño porcentaje durante varias épocas.

Para el modelo VGG16 se obtuvo en la Figura 6 que la pérdida en los datos de entrenamiento se mantenía superior a los de validación donde ambas gráficas decrecieron conforme iteraban las épocas llegando a coincidir.

7. Resultados

Al elaborar este proyecto se llegó a las siguientes conclusiones:

- ✓ Se realizó revisiones bibliográficas de diversos artículos, tesis y revistas para adquirir los conocimientos en el tema.
- ✓ Descripción de los principales componentes de software que conformaron el prototipo.
- ✓ El diseño de un prototipo de SBC utilizando técnicas de inferencia estadística como lo son las redes neuronales mediante la implementación de TensorFlow, capaz de clasificar radiografías torácicas de pacientes con Covid.
- ✓ Comparación del rendimiento entre dos arquitecturas pre-entrenadas como lo son la MobileNetV2 y la VGG16 utilizando transfer learning durante el entrenamiento final.
- ✓ Conocimientos acerca de la enfermedad SARS-CoV-2 y su manifestación en los pulmones.

Se realizó una comparación entre los proyectos “COVID-Net: un diseño de red neuronal convolucional profunda a medida, para la detección de casos de COVID-19 a partir de imágenes de rayos X de tórax” [36] y “Chester: Un sistema de predicción de enfermedad de rayos X de tórax computarizado alojado en la web” [37].

TABLA 3. COMPARACIÓN ENTRE PROYECTOS SIMILARES.

	Arquitectura utilizada	Especializada	Dataset utilizado	Ventajas	Desventajas
Nuestro Proyecto	MobileNetV2 y VGG16	Clasificación de radiografías de personas con Covid-19.	Covid-chestxray-dataset	Fácil reentrenamiento con un conjunto de datos mayor.	Dado el escaso conjunto de datos los modelos clasifican parcialmente.
COVID-Net	COVIDNet-CT	Clasificación de radiografías de personas con Covid-19.	COVIDx	Actualizaciones periódicas de la arquitectura por parte de los autores.	Requiere de un estudio minucioso del código fuente para ser utilizado.
Chester	DenseNet-121	Clasificación de radiografías de acuerdo con un tipo específico de enfermedad pulmonar	NIH Chest-xray14 - Clinical Center, Bethesda, Maryland, USA	Alojamiento Web del prototipo con toda la documentación.	Modelo complejo de entrenar.

8. Pruebas y resultados del sistema

Se preparó un conjunto de imágenes que no fueron utilizados en la validación o el entrenamiento con el objetivo de crear una matriz de confusión para comparar la salida de ambos modelos.




Figura 8. Matriz de confusión de resultados para el modelo MobileNetV2




Figura 9. Matriz de confusión de resultados para el modelo VGG16.

Como se puede observar en la Figura IX la arquitectura MobileNetV2 logra la clasificación correcta de 53 de las 80 imágenes suministradas, siendo un porcentaje de acierto del 63%, fallando en la predicción de 27 radiografías siendo 11 para Covid y 16 para No Covid. Mientras que la red VGG16 acertó 61 de las 80 imágenes logrando un porcentaje de efectividad del 76%, errando en la clasificación de 19 radiografías siendo 9 para Covid y 10 para No Covid.

9. Conclusiones

Los sistemas expertos basados en redes neuronales abren un abanico de posibilidades para resolver problemas complejos como pueden ser la clasificación de imágenes.

Se realizó la propuesta de un sistema el cual fuera capaz de clasificar radiografías torácicas utilizando modelos de redes neuronales convolucionales, el conjunto de datos de entrenamiento resultó escaso para lograr un rendimiento optimo para una implementación del prototipo, el hardware utilizado impidió un entrenamiento extensivo pero gracias a la utilización de modelos pre-entrenados se pudo obtener resultados aceptables en donde la arquitectura VGG16 obtuvo un mejor rendimiento en las pruebas realizadas por sobre la red MobileNetV2.

Gracias a la realización de este proyecto investigativo se pudo llegar a las siguientes conclusiones adicionales:

- La Enfermedad SARS-CoV-2 ha cobrado su tasa de letalidad ya que afecta directamente los pulmones de los pacientes, provocando neumonías que en personas con padecimientos respiratorios puede llegar a ser mortal.

- El acceso a datos de pacientes como las radiografías obedecen a una estricta política de confidencialidad por parte de los hospitales que la realizan, lo que causa escases para datos de entrenamiento, siendo una práctica recomendada en estos casos recurrir a plataformas y repositorios como Kaggle y GitHub donde se pueden encontrar conjuntos de datos preparados por investigadores internacionales.
- Al realizar el entrenamiento de una red neuronal especializada en el tratamiento de imágenes, se debe reflexionar sobre el conjunto de datos que se utilizará, esto se debe enmarcar en una rama de estudio sobre la seguridad de datos de la cual hacen énfasis muchos investigadores internacionales ya que es el componente fundamental de los sistemas basados en visión artificial.
- Entrenar modelos utilizando transfer learning llega a ahorrar tiempo y recursos computacionales brindando resultados óptimos para un conjunto de datos pequeño, las herramientas como TensorFlow y Keras permiten una rápida implementación de esta técnica.
- Las radiografías de tipo torácicas permiten obtener información sobre el estado de los pulmones y otros órganos, siendo una herramienta utilizada por los médicos para diagnosticar el impacto que está teniendo una enfermedad de tipo respiratoria sobre la salud de una persona.

10. Trabajos Futuros

Se espera poder tener un conjunto de datos más extenso y principalmente que provengan de la República de Panamá, además, se pretende consultar a expertos para poder recolectar información acerca de que tipos de transformaciones se le puede aplicar a las radiografías para mejorar la capacidad de entrenamiento.

La fase de entrenamiento puede ser mejorada realizándose en un Hardware con mayores prestaciones pudiendo llegar a obtener mejores resultados con el data set empleado en este proyecto.

Se espera poder implementar el modelo final en un dispositivo móvil para poder brindarle portabilidad al sistema.

RECONOCIMIENTOS

Agradecemos al Profesor Cristian Pinzón de la Facultad de Ingeniería y Sistemas por guiarnos en el desarrollo y confección de este artículo investigativo.

REFERENCIAS

- [1] "COVID-19: cronología de la actuación de la OMS." [Online]. Available: <https://www.who.int/es/news-room/detail/27-04-2020-who-timeline---covid-19>. [Accessed: 31-Jul-2020].
- [2] "Los nombres de la enfermedad por coronavirus (COVID-19) y del virus que la causa." [Online]. Available: [https://www.who.int/es/emergencias/diseases/novel-coronavirus-2019/technical-guidance/naming-the-coronavirus-disease-\(covid-2019\)-and-the-virus-that-](https://www.who.int/es/emergencias/diseases/novel-coronavirus-2019/technical-guidance/naming-the-coronavirus-disease-(covid-2019)-and-the-virus-that-)

- causes-it. [Accessed: 31-Jul-2020].
- [3] H. W. Zhang *et al.*, "Corona Virus International Public Health Emergencies: Implications for Radiology Management," *Acad. Radiol.*, vol. 27, no. 4, pp. 463–467, Apr. 2020.
- [4] "Alocución de apertura del Director General de la OMS en la rueda de prensa sobre la COVID-19 celebrada el 11 de marzo de 2020." [Online]. Available: <https://www.who.int/es/dg/speeches/detail/who-director-general-s-opening-remarks-at-the-media-briefing-on-covid-19---11-march-2020>. [Accessed: 31-Jul-2020].
- [5] "OPS/OMS Panamá - Panamá confirma primer caso de COVID-19." [Online]. Available: https://www.paho.org/pan/index.php?option=com_content&view=article&id=1349:panama-confirma-primer-caso-de-covid-19&Itemid=442. [Accessed: 31-Jul-2020].
- [6] "COVID-19 GIS HUB PANAMA." [Online]. Available: <https://covid19-minsapanama.hub.arcgis.com/>. [Accessed: 31-Jul-2020].
- [7] J. P. Cohen, P. Morrison, and L. Dao, "COVID-19 Image Data Collection."
- [8] Centro de Coordinación de Alertas y Emergencias Sanitarias, "Enfermedad por coronavirus, COVID-19," Jul. 2020.
- [9] "Informe Técnico," 2020.
- [10] S. A. Lauer *et al.*, "The incubation period of coronavirus disease 2019 (CoVID-19) from publicly reported confirmed cases: Estimation and application," *Ann. Intern. Med.*, vol. 172, no. 9, pp. 577–582, May 2020.
- [11] M. Palacios Cruz, E. Santos, M. A. Velázquez Cervantes, and M. León Juárez, "COVID-19, a worldwide public health emergency," *Revista Clínica Espanola*. Elsevier Doyma, 20-Mar-2020.
- [12] "Machine Learning - Libro online de IAAR." [Online]. Available: <https://iaarbook.github.io/ML/>. [Accessed: 01-Aug-2020].
- [13] M. Antonio and M. García, "TESIS DOCTORAL Clasificación multilingüe de documentos utilizando machine learning y la Wikipedia."
- [14] R. G. Duque, "Python PARA TODOS."
- [15] F. J. Fernández and J. Profesor, "Inteligencia Artificial con TensorFlow para predicción de comportamientos."
- [16] A. V. Barrio, "TRABAJO FIN DE MÁSTER," 2017.
- [17] "About Keras." [Online]. Available: <https://keras.io/about/>. [Accessed: 01-Aug-2020].
- [18] "¿Qué es NumPy? - Manual de NumPy v1.19." [Online]. Available: <https://numpy.org/doc/stable/user/whatisnumpy.html>. [Accessed: 01-Aug-2020].
- [19] "Anaconda | Edición individual." [Online]. Available: <https://www.anaconda.com/products/individual>. [Accessed: 01-Aug-2020].
- [20] J. Durán Suárez, A. Del, R. Torres, and D. Suárez, "Redes Neuronales Convolucionales en R Reconocimiento de caracteres escritos a mano Redes Neuronales Convolucionales en R Reconocimiento de caracteres escritos a mano Redes Neuronales Convolucionales en R."
- [21] S. Khan, H. Rahmani, S. A. A. Shah, and M. Bennamoun, "A Guide to Convolutional Neural Networks for Computer Vision," *Synth. Lect. Comput. Vis.*, vol. 8, no. 1, pp. 1–207, Feb. 2018.
- [22] I. B. Roig, "DISEÑO DE TÉCNICAS DE INTELIGENCIA ARTIFICIAL APLICADAS A IMÁGENES MÉDICAS DE RAYOS X PARA LA DETECCIÓN DE ESTRUCTURAS ANATÓMICAS DE LOS PULMONES Y SUS ALTERACIONES AUTORA: TUTOR: Selecccion BELÉN FOS GUARINOS."
- [23] G. Anabel, "Redes Neuronales Convolucionales para Una Clasificación Precisa de Imágenes de Corales," no. February, 2019.
- [24] "Blog de Google AI: MobileNetV2: la próxima generación de redes de visión por computadora en el dispositivo." [Online]. Available: <https://ai.googleblog.com/2018/04/mobilenetv2-next-generation-of-on.html>. [Accessed: 01-Aug-2020].
- [25] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks."
- [26] K. Simonyan and A. Zisserman, "VERY DEEP CONVOLUTIONAL NETWORKS FOR LARGE-SCALE IMAGE RECOGNITION," 2015.
- [27] "Keras Applications." [Online]. Available: <https://keras.io/api/applications/>. [Accessed: 01-Aug-2020].
- [28] "COVID-19 Radiography Database | Kaggle." [Online]. Available: <https://www.kaggle.com/tawsifurrahman/covid19-radiography-database>. [Accessed: 27-Jun-2020].
- [29] "GitHub - lindawang/COVID-Net: COVID-Net Open Source Initiative." [Online]. Available: <https://github.com/lindawang/COVID-Net>. [Accessed: 27-Jun-2020].
- [30] "Chest X-Ray Images (Pneumonia) | Kaggle." [Online]. Available: <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia>. [Accessed: 07-Apr-2020].
- [31] "GitHub - agchung/Actualmed-COVID-chestxray-dataset: Actualmed COVID-19 Chest X-ray Dataset Initiative." [Online]. Available: <https://github.com/agchung/Actualmed-COVID-chestxray-dataset>. [Accessed: 27-Jun-2020].
- [32] "Two public chest X-ray datasets for computer-aided screening of pulmonary diseases." [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4256233/>. [Accessed: 07-Apr-2020].
- [33] "Sensitivity of Chest CT for COVID-19: Comparison to RT-PCR | Radiology." [Online]. Available: <https://pubs.rsna.org/doi/10.1148/radiol.20200432>. [Accessed: 07-Apr-2020].
- [34] "GitHub - ieee8023/covid-chestxray-dataset: We are building an open database of COVID-19 cases with chest X-ray or CT images." [Online]. Available: <https://github.com/ieee8023/covid-chestxray-dataset>. [Accessed: 07-Apr-2020].
- [35] "COVID-19 Detection from X Ray Images of Lungs | Kaggle." [Online]. Available: <https://www.kaggle.com/nabeelsajid917/covid-19-detection-from-x-ray-images-of-lungs>. [Accessed: 07-Apr-2020].
- [36] L. Wang, Z. Q. Lin, and A. Wong, "COVID-Net: A Tailored Deep Convolutional Neural Network Design for Detection of COVID-19 Cases from Chest X-Ray Images."
- [37] J. P. Cohen, P. Bertin, and V. Frappier, "Chester: A Web Delivered Locally Computed Chest X-ray Disease Prediction System," 2020.